

Índice de contenidos

- 1. Procesamiento de lenguaje natural
- 2. Potencial de las técnicas existentes de procesamiento de lenguaje. Limitaciones
 - 1. Potencial de procesamiento del lenguaje natural
 - 1. Reconocimiento del habla (ASR, Automatic Speech Recognition)
 - 2. Síntesis de texto o voz
 - 3. Detección de entidades nombradas (NER, Named Entity Recognition)
 - 4. Traducción automática
 - 5. Similitud de textos
 - 6. Análisis del sentimiento
 - 2. Modelos y técnicas existentes
 - 1. BERT (Bidirectional Encoder Representations from Transformers)
 - 2. Otros modelos
 - 3. Limitaciones. La ambigüedad
- 3. Formación del investigador en PLN.
- 4. Elaboración de un sistema de procesamiento de lenguaje orientado a una tarea específica



Traducción automática



La traducción automática es la tarea de traducir texto de un idioma a otro. Por ejemplo, del inglés al español.

Los modelos se basan en la arquitectura secuencia a secuencia de **Transformer** [nlp-machine_translation4]

Modelos de traducción automática

Visita la página Hugging Face



Traducción automática

```
sudo docker pull nvcr.io/nvidia/nemo:1.5.1
sudo docker run --runtime=nvidia -it -v /mnt/d/docker/
 nemo:/nemo/notebooks/host -p 8888:8888 -p 6006:6006 --shm-
 size=16g --ulimit memlock=-1 --ulimit stack=67108864 nvcr.
 io/nvidia/nemo:1.5.1
from nemo.collections.nlp.models import MTEncDecModel
# Se obtiene el listado de modelos preentrenados disponibles
MTEncDecModel.list_available_models()
# Se descarga el modelo de inglés a español
model = MTEncDecModel.from_pretrained("nmt_en_es_transfor-
mer12x2")
# Se ejecutra sobre la muy conocida frase "Hola Mundo"
                    model.translate(["Hello
                                             World!"7,
translations
source_lang="en", target_lang="es")
print(translations)
```

Traducción automática

```
>>> translations = model.translate(["Hello World!"], source_lang="en", target_lang="es")
>>> print(translations)
['¡Hola mundo!']
>>>
```

Una prueba análoga sobre el acto I de Hamlet arroja el siguiente resultado:

```
>>> translations = model.translate(["Bernardo climbed the stairs to the castle's ramparts. It was a bitter ly cold night. He made his way carefully through the freezing fog to relieve Francisco of his guard duty. He saw a dim figure and challenged him. 'Who's there?' 'No, you answer me!' It was Francisco's voice. 'Sto p and identify yourself!' Bernardo stopped. 'Long live the King!'"], source_lang="en", target_lang="es") (translations)>>> print(translations)
["Bernardo subió las escaleras hasta las murallas del castillo. Era una noche amargamente fría. Se abrió p aso cuidadosamente a través de la helada niebla para liberar a Francisco de su deber de guardia. Vio una f igura tenue y le desafió. '¿Quién está ahí?' '¡No, me respondes!' Era la voz de Francisco. '¡Deténgase e i dentifíquese!' Bernardo se detuvo. '¡Viva el rey!'"]
>>>
```



Algunos modelos (normalmente de tamaño considerable) han sido entrenados de tal forma que las palabras son etiquetadas de manera que aluden a conceptos semánticos.

Ej: un perro es un mamífero y a su vez es un animal.

Un etiquetado correcto situará en lugares más próximos entre sí a un perro y a un gato (dos mamíferos) que un perro y un salmón.

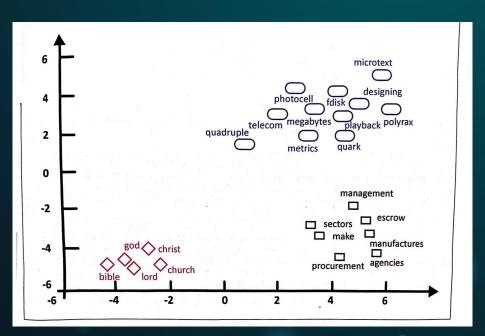
Manazana es una fruta, que es a la vez comida, en una buena lógica sería más "parecido" semánticamente una manzana y una naranja que a un muslo de pollo.



Técnica → *Vectorización y cálculo del coseno*

(dependerá del set de datos que haya sido empleado para llevar el entrenamiento)

? Vectorización de textos



Ej. realizado con Spacy, empleando el diccionario español de mayor tamaño, que ha de ser previamente descargado (es_core_news_lg)

```
import spacy
from spacy import displacy
from collections import Counter
import es_core_news_lg
nlp = es_core_news_lg.load()
doc1 = nlp('Carlos se come una manzana')
doc2 = nlp('María se come una ensalada')
doc3 = nlp('María y carlos se comen un plato de pasta ')
doc4 = nlp('Maria y carlos ven una película')
print(doc1, "<->", doc2, doc1.similarity(doc2))
print(doc1, "<->", doc3, doc1.similarity(doc3))
print(doc1, "<->", doc4, doc1.similarity(doc4))
print(doc3, "<->", doc4, doc3.similarity(doc4))
```

PROBLEMAS SALIDA TERMINAL CONSOLA DE DEPURACIÓN

PS C:\Users\Usuario\Documents\Master UNED\Marcombo> & C:/Python38/python.exe "c:/Users/Usuario/Documents Carlos se come una manzana <-> María se come una ensalada 0.9545383806411006

Carlos se come una manzana <-> María y carlos se comen un plato de pasta 0.6870097213414148

Carlos se come una manzana <-> María y carlos ven una pelicula 0.3394106710397441

María y carlos se comen un plato de pasta <-> María y carlos ven una pelicula 0.4397361911649576

PS C:\Users\Usuario\Documents\Master UNED\Marcombo> |

Las frases 1 y 2 son muy parecidas (95%).

La frase 4 hay una similitud del (43,9%) porque en las dos están María y Carlos pero realizan acciones distintas.

La frase 3 es la que menos similitud tiene con un (33,9%) ya que sólo está Carlos.